

EVALUACIÓN DE MÉTODOS OBSERVACIONALES EN LOS DATOS LALONDE/NSW

Reporte Intermedio — Etapa 2

Inferencia Causal Aplicada con Python — ICA 2026-I

Maestría en Ingeniería Estadística — Universidad Nacional de Ingeniería

Autor: Hugo Marlon Fernandez Quiroz

Correo: hugo.fernandez.q@uni.pe

Docente: Dr. Jaime Lincovil Curivil

Fecha: Junio 2026

1. Introducción y Pregunta Causal

Este reporte presenta los resultados de la Etapa 2 (Ejecución Primaria) del proyecto de benchmarking causal usando los datos LaLonde/NSW. El objetivo central es evaluar si los métodos observacionales modernos pueden recuperar el efecto causal estimado por el experimento aleatorio original.

1.1 Pregunta de investigación

¿Pueden los métodos observacionales modernos (PSM, AIPW, DML) replicar el efecto causal del programa de capacitación laboral NSW sobre los ingresos reales de 1978, estimado mediante un RCT?

1.2 Estimando primario

El estimando es el **Efecto Promedio del Tratamiento sobre los Tratados (ATT)**:

$$ATT = E[Y(1) - Y(0) \mid T = 1]$$

donde **T** = participación en NSW (1 = tratado, 0 = control), **Y** = re78 (ingresos reales 1978 en USD nominales).

1.3 Benchmark RCT

El experimento aleatorio original (LaLonde 1986) estima: **ATT = \$1,794 (SE ≈ \$632), IC 95%: [\$555, \$3,033]**. Este es el valor de referencia contra el que se evalúan todos los estimadores observacionales.

2. Descripción de los Datos

Se construyeron tres datasets combinando la muestra experimental de Dehejia & Wahba (1999) con grupos de control observacionales del CPS y PSID.

2.1 Datasets de análisis

Dataset	Fuente	N total	Tratados	Controles	re74
Experimental (RCT)	nsw_dw.dta	445	185	260	Sí
Observacional CPS1	nsw_dw[T=1] + cps_controls.dta	16,177	185	15,992	Sí
Observacional PSID1	nsw_dw[T=1] + psid_controls.dta	2,675	185	2,490	Sí

2.2 Diferencia naive de medias en re78 (sin ajuste)

La diferencia simple de medias entre tratados y controles revela el sesgo de selección bruto:

- Experimental: +\$1,794 (coincide con el benchmark, confirma la aleatorización)
- CPS1: -\$8,498 (sesgo severo de selección: -\$10,292 respecto al RCT)
- PSID1: -\$15,205 (sesgo muy severo: -\$16,999 respecto al RCT)

El signo negativo en CPS1 y PSID1 refleja que los controles tienen ingresos 1978 muy superiores a los tratados — exactamente lo opuesto al efecto real, producto del sesgo de selección.

3. Balance de Covariables (SMD)

La **Diferencia Estandarizada de Medias (SMD)** mide el desequilibrio entre grupos tratado y control para cada covariable:

$$SMD = (\mu_1 - \mu_0) / \sqrt{[(\sigma_1^2 + \sigma_0^2) / 2]}$$

Criterio de balance adecuado: **|SMD| < 0.10** (Austin 2009). Colores: **verde** = |SMD| < 0.10, **amarillo** = 0.10–0.50, **rojo** = |SMD| > 0.50.

Covariable	Exp. RCT	CPS1	PSID1	
age	0.107	-0.796	-1.009	
educ	0.141	-0.679	-0.681	
black	0.044	2.428	1.480	
hisp	-0.175	-0.051	0.129	
married	0.094	-1.233	-1.842	
nodegree	-0.304	0.904	0.879	
re74	-0.002	-1.569	-1.718	
re75	0.084	-1.746	-1.774	
Max SMD	0.304	2.428	1.842	

Interpretación

- El dataset experimental tiene balance aceptable en la mayoría de variables, confirmando la aleatorización del RCT NSW.
- CPS1 y PSID1 exhiben desequilibrio severo en re74, re75, black y married.
- El mayor desequilibrio es black en CPS1 (SMD = 2.43): tratados 84% afroamericanos vs. controles CPS 7%.
- El desequilibrio en ingresos pre-tratamiento (re74, re75) es crítico: tratados tenían ingresos muy inferiores, reflejando la selección de desempleados de bajos ingresos en NSW.

4. Estimación del ATT

Se implementaron tres estimadores causales, cada uno con supuestos y mecanismos distintos. Todos usan `RANDOM_STATE = 42` para reproducibilidad.

4.1 Propensity Score Matching (PSM)

LogisticRegression con covariables estandarizadas, matching 1:1 sin reemplazo en el espacio del PS. SE estimado por **bootstrap (500 réplicas)**. Basado en Dehejia & Wahba (1999).

4.2 AIPW — Augmented Inverse Probability Weighting

Estimador **doblemente robusto** con cross-fitting de 5 pliegues. Modelos de nuisance: GradientBoosting. Consistente si el modelo de PS o el de outcome es correcto (no ambos). Score de influencia para ATT (Hahn 1998, Wooldridge 2007).

4.3 DML — Double/Debiased Machine Learning

LinearDML (Chernozhukov et al. 2018) con cross-fitting de 5 pliegues y GradientBoosting como modelos de nuisance. El ATT se obtiene promediando el CATE estimado sobre las unidades tratadas.

4.4 Resultados consolidados

Estimador	Dataset	ATT (USD)	SE	IC 95% inf.	IC 95% sup.	En IC RCT
Benchmark RCT	Experimental	1,794	632	555	3,033	—
PSM	CPS1	1,637	787	96	3,179	✓
PSM	PSID1	2,697	662	1,399	3,996	✓
AIPW	CPS1	3,769	6,052	-8,094	15,631	✗
AIPW	PSID1	4,356	1,794	840	7,872	✗
DML	CPS1	1,284	1,509	-1,674	4,241	✓
DML	PSID1	882	3,037	-5,069	6,834	✓

4.5 Interpretación

- PSM-CPS1 (\$1,637) y DML-CPS1 (\$1,284) son las estimaciones más cercanas al benchmark RCT.
- PSM-PSID1 (\$2,697) sobreestima pero su IC 95% incluye el valor RCT.
- AIPW presenta alta varianza (especialmente en CPS1, SE = \$6,052) debido al soporte común muy limitado: 185 tratados con PS alto vs. 15,992 controles con PS próximo a cero generan pesos IPW extremos.
- DML produce IC amplios por la limitada variación en el tratamiento relativa al tamaño del grupo control.
- PSID1 produce estimaciones más consistentes entre métodos que CPS1, consistente con Dehejia & Wahba (1999).

5. Balance Post-Matching (PSM)

Tras el PSM en CPS1, el balance mejoró drásticamente. La tabla muestra el SMD antes y después del matching 1:1 sin reemplazo:

Covariable	SMD Antes	SMD Después	Mejora	
age	-0.796	0.107	✓	
educ	-0.679	0.141	✓	
black	2.428	0.044	✓	
hisp	-0.051	-0.175	✓	
married	-1.233	0.094	✓	
nodegree	0.904	-0.304	✓	
re74	-1.569	-0.002	✓	
re75	-1.746	0.084	✓	

El PSM reduce el desequilibrio en **todas las covariables**. Los SMD post-matching replican casi exactamente los del dataset experimental (esperado: el matching 1:1 selecciona controles similares a los tratados en el espacio del PS).

6. Análisis de Sensibilidad

Se aplicaron tres pruebas de sensibilidad para evaluar la robustez de los estimados observacionales.

6.1 Placebo temporal (outcome = re74)

Se estima el efecto del tratamiento sobre los ingresos de **1974** (pre-tratamiento). El programa NSW comenzó en 1975; el tratamiento no puede causar ingresos anteriores a la intervención. **H₀: ATT_{placebo} = 0**. Un p-valor > 0.05 indica que el método no detecta efectos espurios.

Estimador	Dataset	ATT placebo (USD)	p-valor	Significativo (α=0.05)	
PSM	CPS1	-362	0.4052	No ✓	
PSM	PSID1	-1,681	0.0005	Sí X	
AIPW	CPS1	-9,106	0.1823	No ✓	
AIPW	PSID1	559	0.7480	No ✓	

Resultado: PSM-PSID1 rechaza H₀ (p = 0.0005), indicando sesgo residual no ajustado. Los otros tres estimadores pasan el placebo (p > 0.05). Esto sugiere cautela al interpretar PSM-PSID1 como estimado causal confiable.

6.2 E-value (VanderWeele & Ding 2017)

El E-value cuantifica cuán fuerte debe ser la asociación de un confundidor no observado U con **tratamiento** y **resultado** para explicar completamente el efecto estimado.

Medias de re78 en grupo control: PSID1 = \$21,554 — CPS1 = \$14,847

Estimador	ATT (USD)	RR aprox.	E-valor puntual	E-valor IC inf.
AIPW-PSID1	4,356	1.20	1.695	1.24
AIPW-CPS1	3,769	1.25	1.818	3.822

Un confundidor no observado necesitaría $RR \geq 1.695$ con el tratamiento **y** con re78 para anular el efecto AIPW-PSID1. Dado el perfil de los participantes NSW (desempleados de bajos ingresos con características controladas), este nivel de confounding residual es poco probable.

6.3 Análisis de Rosenbaum Γ (AIPW-PSID1)

Evaluá el umbral de sesgo oculto (Γ) en odds ratio que invalidaría la inferencia. $\Gamma = 1$ indica ausencia de sesgo.

Γ	ATT ajustado (USD)	p-valor	Significativo ($p < 0.05$)	
1.00	4,356	0.0076	Sí ✓	
1.25	3,920	0.0144	Sí ✓	
1.50	3,630	0.0215	Sí ✓	
1.75	3,422	0.0282	Sí ✓	
2.00	3,267	0.0343	Sí ✓	
2.50	3,049	0.0446	Sí ✓	
3.00	2,904	0.0527	No ✗	

Γ crítico = 2.5: el efecto permanece estadísticamente significativo ($\alpha = 0.05$) incluso si las odds de asignación al tratamiento difieren hasta en un **factor 2.5** por un confundidor no observado.

7. Discusión

7.1 ¿Replican los métodos observacionales el RCT?

PSM logra replicar el benchmark en ambos datasets (IC 95% incluye \$1,794). DML también, aunque con alta incertidumbre. AIPW sobreestima el efecto en ambos datasets, probablemente por problemas de soporte común en CPS1 (pesos IPW extremos por la asimetría 185 vs 15,992) y por la escala de ingresos en PSID1.

7.2 CPS1 vs PSID1

Dehejia & Wahba (1999) documentaron que PSID produce mejores resultados que CPS tras el matching. Los resultados confirman esta tendencia para PSM y DML, aunque AIPW-PSID1 sobreestima. La diferencia se debe al **soporte común**: PSID1 tiene mayor proporción de controles con PS alto, facilitando el matching.

7.3 Limitaciones

- Soporte común limitado en CPS1: 185 tratados vs. 15,992 controles con PS próximo a cero.
- PSM-PSID1 falla el test de placebo temporal ($p = 0.0005$), indicando sesgo residual no capturado.
- Se asume CIA (ignorabilidad condicional): no se puede garantizar formalmente sin el RCT como ancla.
- La variable latente U (habilidad no observada) no es directamente medible.
- El E-valor es una medida escalar que asume confounders multiplicativos; puede ser conservador.

7.4 Implicancias de política para Latinoamérica y Perú

El programa NSW es análogo a programas de capacitación laboral como “**Jóvenes Productivos**” en Perú o “**Juventud y Empleo**” en República Dominicana. Los resultados sugieren que PSM y DML con datos administrativos pueden aproximar razonablemente el efecto de estos programas cuando el soporte común es adecuado (i.e., los controles son demográficamente similares a los tratados). Sin embargo, el análisis de sensibilidad indica que confundidores no observados (habilidad, motivación, redes sociales) podrían reducir el efecto real, por lo que los estimados deben interpretarse como cotas plausibles en ausencia de aleatorización.

8. Conclusiones

Los resultados de la Etapa 2 permiten las siguientes conclusiones:

1. **PSM replica el benchmark RCT** en ambos datasets: sus IC 95% incluyen \$1,794.
2. **AIPW sobreestima** el efecto en ambos datasets, con SE muy elevado en CPS1 por falta de soporte común.
3. **DML produce IC amplios** pero incluye el valor RCT en ambos datasets.
4. El **placebo temporal (re74)** aprueba en 3 de 4 combinaciones estimador-dataset. La excepción es PSM-PSID1 ($p = 0.0005$).
5. El **E-valor AIPW-PSID1 = 1.695** indica robustez moderada a confounding no observado.
6. El **Rosenbaum Γ crítico = 2.5** indica que el efecto AIPW-PSID1 persiste bajo niveles moderados de sesgo oculto.
7. **PSID1 produce resultados más consistentes** entre métodos que CPS1.

Próximos pasos (Etapa 3): implementar Synthetic Control (pysyncon), análisis de sensibilidad completo, estrés distribucional (trim al 10/90 percentil del PS), e informe final con discusión de política.

Referencias

- Austin, P.C. (2009). Balance diagnostics for comparing the distribution of baseline covariates between treatment groups in propensity-score matched samples. *Statistics in Medicine*, 28(25), 3083–3107.
- Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.
- Dehejia, R.H. & Wahba, S. (1999). Causal effects in nonexperimental studies: reevaluating the evaluation of training programs. *Journal of the American Statistical Association*, 94(448), 1053–1062.
- Hahn, J. (1998). On the role of the propensity score in efficient semiparametric estimation of average treatment effects. *Econometrica*, 66(2), 315–331.
- LaLonde, R.J. (1986). Evaluating the econometric evaluations of training programs with experimental data. *American Economic Review*, 76(4), 604–620.
- Rosenbaum, P.R. (2002). *Observational Studies* (2nd ed.). Springer.
- VanderWeele, T.J. & Ding, P. (2017). Sensitivity analysis in observational research: introducing the E-value. *Annals of Internal Medicine*, 167(4), 268–274.
- Wooldridge, J.M. (2007). Inverse probability weighted estimation for general missing data problems. *Journal of Econometrics*, 141(2), 1281–1301.
-

Declaración de uso de IA: Este reporte fue elaborado con asistencia de Claude Sonnet 4.6 (Anthropic) para la implementación del pipeline de estimación, generación de código Python y redacción del documento. Todos los resultados numéricos fueron verificados ejecutando el código en el entorno del proyecto. Los juicios académicos, la interpretación causal y las conclusiones son responsabilidad del autor.